

ANÁLISE ESTATÍSTICA DE RESULTADOS

Carlos Frederico Carvalheira Mello

Introdução e Objetivos

A análise estatística dos resultados tem como objetivo mensurar aspectos como acurácia, precisão, quantidade de falsos negativos e positivos da saída de um modelo de aprendizado de máquina, fazendo assim uma maneira efetiva de validar quantitativamente o desempenho do modelo.

Metodologia

No caso deste usei aspectos como acurácia, precisão positiva e negativa e quantidade de falsos negativos e positivos para medir a performance da saída do modelo.

Ao princípio fiz a leitura do arquivo enviado e para facilitar transformei-o para um DataFrame. Foram feitas limpeza em dados faltantes e conversão de valores do tipo Object para valores do tipo float64, isso é necessário por conta do formato do arquivo ser em Excel

Após essa leitura resolvi para facilitar ainda mais o cálculo de algumas métricas dividir o dataset original em dois novos; Um contando com os targets positivos e outro com os negativos.

Para completar criei uma lista contendo 11 valores de thresholds para dividir os valores positivos dos negativos, variando um décimo entre 0.0 e 1.0 e fiz o calculo das seguintes métricas: Acurácia, Precisão Positiva, Precisão Negativa, Quantidade Falso Positivo e Quantidade Falso Negativo.

Resultados e Conclusões

A acurácia se manteve em torno dos 60% com o threshold entre 0.4 e 0.7. Abaixo ou acima disso a acurácia aumenta significativamente mas decai valores como precisão de positivo ou negativo e aumenta a quantidade de falsos positivos e negativos. Como exemplo segue a saída de alguns:

```
Threshold: 0.1
Accuracy: 0.662
Positive Precision: 1.0
Negative Precision: 0.30165289256198347
Amount False Positives: 0.0
Amount False Negatives: 0.6550387596899225
```

```

Threshold: 0.8
Accuracy: 0.612
Positive Precision: 0.24806201550387597
Negative Precision: 1.0
Amount False Positives: 0.8016528925619835
Amount False Negatives: 0.0

```

```

Threshold: 0.5
Accuracy: 0.642
Positive Precision: 0.6395348837209303
Negative Precision: 0.6446280991735537
Amount False Positives: 0.384297520661157
Amount False Negatives: 0.3333333333333333

```

Podemos observar que se o threshold ficar muito próximo a zero a precisão de valores positivos fica igual a 1.0 ou seja estamos aceitando quase todo valor de resposta como positivo e inverso acontece com um valor mais alto de threshold onde aceitamos quase todos os valores como negativo, aumentando assim a precisão da saída negativa.

Resolvi então escolher um valor de threshold de 0.7 para exemplificar uma Matrix de confusão com a figura de HeatMap(Figura 1.1). Podemos ver então que com esse valor de limiar temos uma quantidade muito grande de Verdadeiros Negativos, relativamente alto um valor de Verdadeiro Positivo e valores baixos para Falso Positivo e Negativo.

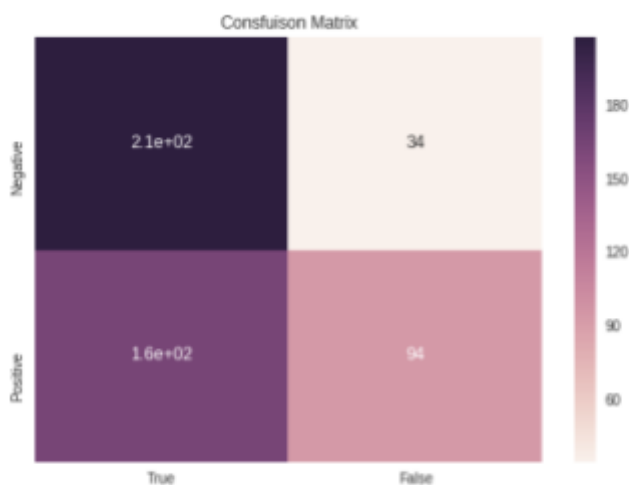


Figura 1.0

Para completar uma curva do tipo Receiver Operating Characteristic(ROC) foi plotada para poder verificar cada taxa de Verdadeiro Positivo versus a taxa de Falso Positivo.

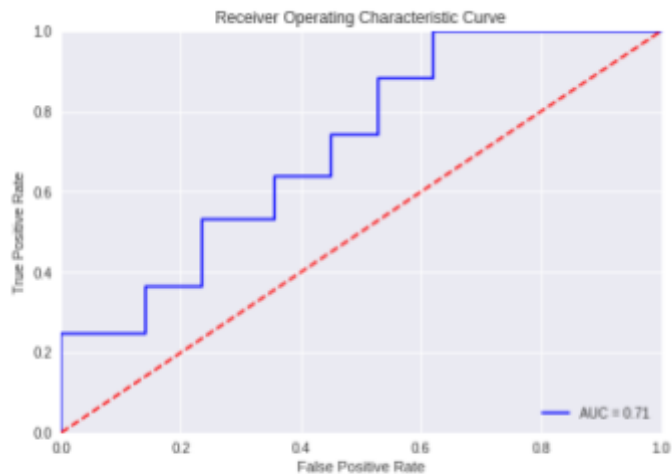


Figura 1.2

Em conclusão a curva ROC e a Matrix de Confusão junto com a análise iterativa dos thresholds confirmam a ideia que o valor da acurácia e precisão de um modelo pode ser alterado em função de qual limiar é estipulado para aceitar as respostas como positivo e negativo e talvez a escolha de um limiar “neuro” como um valor de 0.5 pode ser uma boa escolha para determinar uma análise mais imparcial dos resultados.